Министерство науки и высшего образования Российской Федерации

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО

Домашняя работа №3

по дисциплине

«Инженерия данных»

Семестр V

Вариант 5

Выполнил:
студент
Черницын Егор Артёмович
гр. J3310
ИСУ: 467993

Санкт-Петербург
2026

Цель работы

Для вакансий «Программист, разработчик на PHP» прочитать данные из RustFS, посчитать частоты навыков, пар и троек двумя способами, проверить совпадение и сравнить время и память. Дополнительно сравнить зарплаты по наборам навыков и три региона.

Хранилище и выборка

RustFS 1.0.0 запущен на Windows в четырёх локальных процессах с папками `vol1--vol4`. S3-порты: 9110, 9120, 9130 и 9140. Консоль первого узла: 9111. Использована схема EC:2. Все папки находятся на одном компьютере.

```
python src/start_rustfs.py --binary rustfs.exe
python src/run_all.py --csv vacancies.csv
```

Объект в бакете `hh-lake`	Размер, байт	Строк
`raw/it_vacancies_2024.csv`	847 619 384	229 388
`segments/php.csv`	18 705 639	5 379

SHA-256 исходного CSV:

```
303db922b541e4440906f5a7e8be32fb
55e8808f950ffddb8c272f1548212a65
```

Загрузка и подготовка заняли 17,943 с. Перед расчётами и после них размер и ETag исходного объекта не изменились.

Оба метода читают через S3 полный исходный CSV. Роль должна быть равна «Программист, разработчик», а в названии должно встречаться отдельное слово PHP без учёта регистра. Получено 5 379 вакансий; навыки указаны в 4 377 из них.

Частоты навыков

Навыки разделены точкой с запятой, приведены к нижнему регистру, очищены от пробелов и повторов в одной вакансии. Частота

набора — число вакансий, где присутствуют все его навыки. Порядок внутри набора не учитывается.

MapReduce читает ответ S3 как поток CSV, делит его на чанки по 1 000 строк и передаёт четырём mapper-процессам. Одновременно ожидают не более восьми чанков. Mapper выбирает вакансии варианта и считает сочетания; reducer складывает частоты одинаковых наборов.

```
for size in (1, 2, 3):
    skills = vacancy["skills"]
    counts[size].update(combinations(skills, size))
```

DuckDB использует `httpfs` и `read_csv` для того же S3-объекта. Условие варианта записано отдельно в SQL:

```
WHERE lower(trim(role)) = 'программист, разработчик'
  AND regexp_matches(lower(name),
      '(^|[^\p{L}\p{N}_])php($|[^\p{L}\p{N}_])')
```

SQL разворачивает список навыков с их позициями. Для пары соединяются позиции $a < b$, для тройки — $a < b < c$. Затем `GROUP BY skills` считает частоты. Полный запрос находится в `sql/php_counts.sql`.

Размер набора	Разных наборов	Всего вхождений
1	953	31 813
2	15 914	135 284
3	127 455	471 899

Рост объясняется числом сочетаний: из n навыков одной вакансии получаются $\binom{n}{1}$ одиночных наборов, $\binom{n}{2}$ пар и $\binom{n}{3}$ троек. Например, из 10 навыков образуются 10 одиночных наборов, 45 пар и 120 троек. Суммы частот совпали с суммами этих сочетаний по выбранным вакансиям.

Размер	Самые частые наборы	Вакансий
1	php; mysql; git	4 031; 2 261; 1 809
2	mysql + php; git + php; laravel + php	2 094; 1 686; 1 342
3	git + mysql + php; javascript + mysql + php; laravel + mysql + php	1 030; 717; 696

Проверены все 144 322 строки частот MapReduce и DuckDB: результаты полностью равны в двух прогревах и шести измеряемых запусках. Все три таблицы `skills_1.csv`, `skills_2.csv`, `skills_3.csv` загружены в `hh-lake/results/php/` и прочитаны обратно без изменений.

```
MapReduce: selected_rows=5379, chunks=230
           different_sets=144322
DuckDB: selected_rows=5379, different_sets=144322
All MapReduce and DuckDB results match
```

Время и память

Каждый метод запускался в отдельном процессе: один прогрев и три измерения. Время включает запуск Python, чтение из S3, расчёт и запись результата. Пик памяти — максимальная наблюдённая сумма RSS клиента и дочерних процессов; опрос проводился каждые 20 мс. Процессы RustFS в показатель не входят. Кэш ОС и RustFS между запусками не очищался.

Метод	Запуск	Время, с	Пик RSS, МиБ
MapReduce	1	14,350	254,5
MapReduce	2	14,132	253,5
MapReduce	3	13,192	248,7
DuckDB	1	6,542	1 370,1
DuckDB	2	6,744	1 350,1
DuckDB	3	6,452	1 357,1
MapReduce, медиана		14,132	253,5
DuckDB, медиана		6,542	1 357,1

По медиане DuckDB быстрее в 2,16 раза, а пик RSS выше в 5,35 раза. Это сравнение двух локальных запусков на одном наборе данных, а не оценка масштабирования на кластере.

Навыки и зарплата

Сопоставимая зарплата найдена у 2 527 вакансий. Общая медиана равна 150 000 руб. Учитываются только RUR/RUB и `gross=false`. Для

двух положительных границ используется их среднее, для одной — её значение; перевёрнутые интервалы исключены.

Для пары базой является более частый навык, для тройки — более частая содержащаяся пара. Сравниваются медианы вакансий с полным набором и с базой. В каждой группе должно быть не менее 20 вакансий с зарплатой. Разница не является причинной оценкой стоимости обучения навыку.

Набор; база	Зарплат, полный/база	Медианы, тыс. руб.	Разница, тыс.
highload + mysql; mysql	23 / 1241	350 / 150	+200
solid + yii2; yii2	20 / 188	350 / 172,5	+177,5
mvc + symfony; symfony	26 / 359	100 / 180	-80
joomla cms + php; php	30 / 1997	67,5 / 145	-77,5

Тройка; базовая пара	Зарплат, тройка/база	Медианы, тыс. руб.	Разница, тыс.
highload + mysql + php; mysql + php	23 / 1151	350 / 145	+205
php7 + postgresql + ооп; postgresql + ооп	23 / 128	350 / 150	+200
mvc + php + symfony; php + symfony	26 / 337	100 / 180	-80
php + php5 + postgresql; php + postgresql	22 / 471	100 / 180	-80

Наибольшая положительная разница у сочетаний с `highload`, отрицательная — у приведённых групп с `mvc`, `joomla cms` и `php5`. Группы могут различаться также по опыту, типу компаний и другим признакам.

Три региона

Выбраны регионы с наибольшим числом PHP-вакансий варианта.

Регион	Вакансий	С зарплатой	Медиана, тыс.	Q25–Q75, тыс.
Москва	2 127	875	175	130–230
Санкт-Петербург	789	397	150	115–200
Новосибирск	215	109	140	90–200

Регион	Навык, вакансий	Пара, вакансий	Тройка, вакансий
Москва	php, 1 548	mysql + php, 749	git + mysql + php, 368
Санкт-Петербург	php, 602	mysql + php, 344	git + mysql + php, 165
Новосибирск	php, 159	git + php, 72	git + laravel + php, 31

Медиана в Москве на 25 тыс. руб. выше, чем в Санкт-Петербурге, и на 35 тыс. руб. выше, чем в Новосибирске. Во всех трёх регионах самый частый одиночный навык — PHP. В Москве и Санкт-Петербурге лидирует пара MySQL + PHP, в Новосибирске — Git + PHP. Для региональных троек также рассчитаны частоты и медианы в `results/analysis.json`.

Вывод

Реализации MapReduce и SQL дали одинаковые частоты по всем одиночным навыкам, парам и тройкам. DuckDB выполнил этот расчёт быстрее, MapReduce потребовал меньше памяти. Зарплатные различия помогают выделить группы вакансий для дальнейшего анализа, но сами по себе не доказывают влияние навыка на оплату.

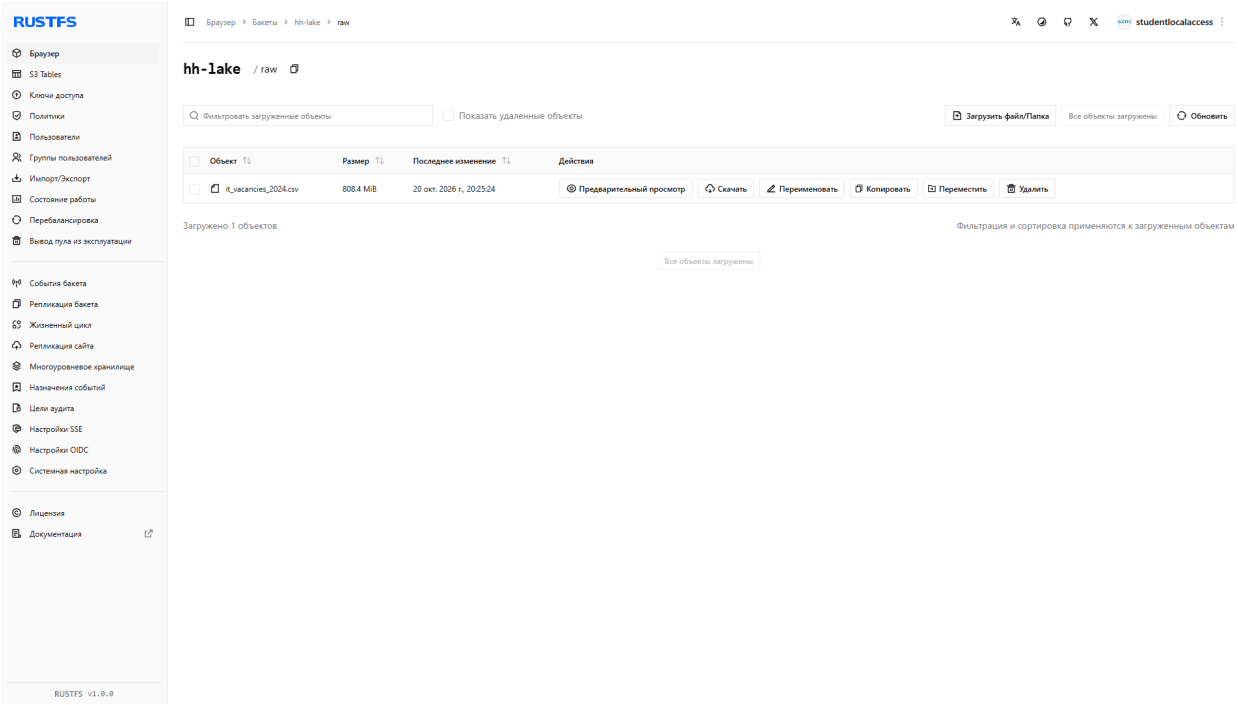
Сохранённые результаты

Все итоговые CSV загружены в RustFS и прочитаны обратно для проверки байтового совпадения. Локальные копии лежат в папке `results`.

Объект в `hh-lake/results/php/`	Строк	Байт
`skills_1.csv`	953	29 278
`skills_2.csv`	15 914	689 735
`skills_3.csv`	127 455	7 197 658

Замеры находятся в `results/benchmark.json`, проверка равенства — в `results/verification.json`, а региональные и зарплатные расчёты — в `results/analysis.json`. Выводы каждого запуска сохранены в папке `evidence`.

Скриншот: исходный CSV в RustFS



Скриншот: результаты в RustFS

